

TEKNIK ANALİZ RAPORU

İKA Otonom Sürüş Sistemleri İçin 3D Nesne Tespit Analizi

Buğra PERGEL

230212045

Derin Öğrenme

Dr. Öğr. Üyesi Murat ŞİMŞEK

KITTI LiDAR Verisi Üzerinde PointPillars Mimarisi ile

Gerçek Zamanlı 3D Nesne Tespiti Analizi

Donanım Platformu	NVIDIA RTX GPU — CUDA Hızlandırmalı Yerel İstasyon
Yazılım Yığını	Python · Open3D · NumPy · PointPillars
Veri Seti	KITTI LiDAR — Ham .bin Formatı
Uygulama Alanı	İnsansız Kara Araçları (İKA) — Otonom Sürüşü
Surum	Rev 1.0 — Mayıs 2025

1. ABSTRACT

Bu rapor, **KITTI LiDAR** veri seti üzerinde **PointPillars** mimarisi kullanılarak gerçekleştirilen 3D nokta bulutu (Point Cloud) tabanlı nesne tespiti çalışmasının kapsamlı bir teknik analizini sunmaktadır. Lidar sensörleri tarafından üretilen ham .bin formatındaki seyrek nokta bulutları, Python ekosistemi (**Open3D**, **NumPy**) ile işlenerek sürücüsüz araç algılama algoritmalarının temelini oluşturan **3D Bounding Box** tahminlerine dönüştürülmektedir.

Çalışmanın birincil motivasyonu; **İnsansız Kara Araçları (İKA)** için güvenli, düşük gecikmeli ve yüksek doğruluklu bir algılama katmanı inşa etmektir. PointPillars mimarisinin dikey sütun (**pillar**) tabanlı veri temsili sayesinde, geleneksel 3D evrişimli sinir ağlarına (3D CNN) kıyasla yaklaşık **2-4x hız kazanımı** elde edilmektedir. **Bird's Eye View (BEV)** projeksiyonu, çakışan nesnelerin yüksek doğrulukla ayrıştırılmasını mümkün kılmakta; **Intersection over Union (IoU)** metriği ise model performansını 3D uzayda nicel olarak değerlendirmektedir.

Yerel **NVIDIA RTX GPU** üzerinde **CUDA** paralelizasyonu ile yürütülen bu sistem; bulut tabanlı ortamların barındırdığı bant genişliği ve I/O darboğazlarını ortadan kaldırarak, gerçek zamanlı operasyonel koşullara (İKA saha görevleri) uygun, yüksek performanslı bir altyapı sunmaktadır.

ANAHTAR SOZCUKLER	3D Object Detection · PointPillars · KITTI LiDAR · Bird's Eye View (BEV) · IoU · Voxelization · ROI Filtering · 7-DoF Bounding Box · CUDA Acceleration · İKA		
Parametre	Bulut Tabanlı	Yerel RTX İstasyonu	Mühendislik Kazanımı
Veri Okuma Hızı	10-50 MB/S	3500 MB/S	I/O darboğazı %98 oranında önlendi.
İşlem Gecikmesi	100 ms (Ağ gecikmeli)	5-15 (Yerel CUDA)	Gerçek zamanlı eşik yakalandı.
Veri Hacmi Yönetimi	Kısıtlı (Upload gerektirir)	Sınırsız (24 GB+ KITTI)	Büyük veri setlerinde kesintisiz işlem.

2. DATA REPRESENTATION (Veri Temsili)

2.1 LiDAR Nokta Bulutunun Yapısal Özellikleri

KITTI veri setinde her LiDAR taraması, **Velodyne HDL-64E** sensöründen elde edilen ve ortalama **100.000 ile 150.000 nokta** içeren bir nokta kümesi olarak depolanmaktadır. Her nokta; Kartezyen koordinatlar (x, y, z) ve yüzey malzemesinin lazer ışınına ne ölçüde yansıttığını kodlayan **Reflection Intensity (r)** değerinden oluşan dört boyutlu bir vektör (x, y, z, r) ile temsil edilmektedir.

Seyreklik (Sparsity) Problemi

LiDAR verisinin temel yapısal zorluğu, uzamsal olarak son derece seyrek dağılmasıdır. Gerçek dünya sahnesini kaplayan hacimsel uzayın yalnızca küçük bir kısmı ölçüm noktası içermektedir. Bu durum üç temel mekanizmadan kaynaklanmaktadır:

- **Mesafeyle Azalan Yoğunluk:** Sensörden uzaklaştıkça ışın huzmelerinin arıksal aralığındaki genişlemesi, birim hacme düşen nokta sayısını $1/r^2$ oranında azaltır.
- **Oklüzyonlar (Gölgeleme):** Bir nesnenin önündeki cisimler, arkadaki nesnelere ait nokta bilgisinin tamamen kaybolmasına (veri boşluğu) yol açar.
- **Yatay Tarama Geometrisi:** 64 katmanlı Velodyne sensörü, dikey eksen boyunca yalnızca sınırlı açısal çözünürlük sağlamaktadır.

2.2 Voxelization: Düzensizden Yapısal Temsile

Ham nokta bulutları, koordinat başlangıçlarından oluşan düzensiz listelerdir ve standart **Evrişimli Sinir Ağları (CNN)** mimarileri bu formata doğrudan uygulanamaz. **Voxelization** işlemi, bu seyrek ve düzensiz uzayı sabit boyutlu, yapısal ve paralel işlenebilir bir veri yapısına dönüştürmektedir.

Parametre	Tanim	Tipik Deger
Voxel Boyutu (dx, dy, dz)	Her bir voksel hucresinin uzamsal cozunurlugu	0.16 x 0.16 x 4.0 m
X Araligi (ROI)	Algilama bolgesinin arac ilerleyis yonu	[0, 69.12] m
Y Araligi (ROI)	Yanal algilama bolgesi	[-39.68, 39.68] m
Z Araligi (ROI)	Yukseklik filtresi — zemin ve gurultu eleme	[-3.0, 1.0] m
Maks. Voxel Sayisi	GPU bellek butcesi kisiti	≤ 20.000
Maks. Nokta / Voxel	Her hucrede kodlanan maksimum nokta	≤ 35

Tablo 2.1 — PointPillars Mimarisi icin Standart Voxelization Parametreleri (KITTI Konfigurasyonu)

PointPillars mimarisinde voksel yapisi özel bicimde uygulanir: z ekseni boyunca sinirsiz yukseklige sahip dikey sutunlar (pillars) olusturularak tamamen iki boyutlu bir ozellik haritasina indirgenir. Bu yaklasim, 3D evrisim islemlerinin buyuk hesaplama yukunu tamamen ortadan kaldirmakta ve FLOPs acisinden dramatik bir tasarruf saglamaktadir.

HIZLANMA ETKISI

Voxelization + Pillar Encoder: Geleneksel 3D CNN yaklasimi ~30ms/kare iken PointPillars BEV projeksiyonu ~5-10ms/kare. RTX GPU'da toplam cikarim suresi $\leq 25ms$ (≥ 40 FPS), IKA gercek zamanli calisma esiginin (33ms) altinda.

3. METHODOLOGY

3.1 ROI (Region of Interest) Filtreleme

Ham LiDAR taraması, aracın 360 derece çevresindeki tüm noktaları kapsamakta ve operasyonel açıdan anlamsız bilgiler (gökyüzü noktaları, çok uzak nesneler, zemin yüzeyi) barındırmaktadır. Bu nedenle, modele veri beslenmeden önce bir **ROI filtresi** uygulanması hem hesaplama verimliliği hem de algılama doğruluğu açısından kritik önem taşımaktadır.


ROI filtresi, üç ekseninde sıkı sınırlar tanımlayarak aracın ilerleyiş yönünde ve etrafındaki operasyonel güvenlik bölgesini izole etmektedir.

- **Z-ekseni Analizi:** Alt sınır (-3.0 m) zemini ve altyapı gürültüsünü temizlerken; üst sınır (+1.0 m) atmosferik saçılmaları elemektedir.
- **Veri Optimizasyonu:** Bu filtreleme işlemi, tipik olarak ham nokta sayısını **%60-75 oranında** azaltarak ardıl Voxelization adımının hesaplama yükünü önemli ölçüde hafifletmektedir.

3.2 7-DoF Bounding Box Temsili

Otonom sürüşte tespit edilen nesnelerin konumu, boyutu ve yönelimi **7 serbestlik derecesiyle (7 Degrees of Freedom — 7-DoF)** tam olarak tanımlanmaktadır. 2D nesne tespitindeki 4 parametreliliği (x, y, w, h) dikdörtgen gösteriminin aksine, 3D bounding box nesnenin uzamsal durumunu eksiksiz biçimde kodlar

Parametre	Mühendislik Fonksiyonu	Kazanım Değeri
Location (x, y, z)	Nesne merkezinin 3D koordinatı.	Engele olan net metrik uzaklık tahmini.
Dimensions (l, w, h)	Nesnenin fiziksel boyutları.	Manevra alanı ve hacimsel engel tespiti.
Rotation (y) / Yaw	Nesnenin bakış açısı (Heading).	Nesnenin hareket doğrultusu tahmini.



Parametre	Sembol	Aciklama
Merkez X	cx	BEV düzleminde boyuna eksen konumu (m)
Merkez Y	cy	BEV düzleminde yanal eksen konumu (m)
Merkez Z	cz	Yükseklik eksen — nesnenin zemine uzaklığı (m)
Uzunluk	l	Nesnenin ilerleyiş yönündeki boyutu (m)
Genislik	w	Nesnenin yanal boyutu (m)
Yükseklik	h	Nesnenin dikey boyutu (m)
Yaw Acisi	θ	BEV düzlemindeki donme acisi — heading yönü (rad)

Tablo 3.1 — 7-DoF 3D Bounding Box Parametre Tanımları

Yaw acisi (θ), özellikle arac tespitinde kritik rol üstlenmektedir. Bir sürücüsüz aracın yol kavsaklarına yaklaşıırken karsıdan gelen aracın hareket yönünü (heading) doğru tahmin edebilmesi; carpsime önleme ve yorunge planlama modüllerine hayati girdi sağlar. Hatalı bir yaw tahmini, kinematik durum kestirimi zincirini (Kalman filtresi) bozarak tehlikeli manevra kararlarına yol açabilir.

IoU Metrigi: 3D Uzayda Performans Değerlendirmesi

Bounding box tahminlerinin kalitesi, 3D Intersection over Union (IoU) metrigi ile ölçülmektedir. IoU, tahmin edilen kutu ile gerçek kutu (ground truth) arasındaki örtüşme oranını ifade etmektedir:

$$IoU_3D = |B_pred \cap B_gt| / |B_pred \cup B_gt|$$

Sinif	IoU Esigi (KITTI)	Zorluk Seviyesi
Arac (Car)	≥ 0.70	Easy / Moderate / Hard
Yaya (Pedestrian)	≥ 0.50	Easy / Moderate / Hard
Bisikletli (Cyclist)	≥ 0.50	Easy / Moderate / Hard

Tablo 3.2 — KITTI Benchmark IoU Esik Değerleri

4. HARDWARE OPTIMIZATION

4.1 Yerel GPU vs. Bulut Tabanlı Ortamlar: Bant Genişliği Analizi

Derin öğrenme projelerinde Google Colab gibi bulut tabanlı ortamlar kolay erişebilirlik sunmakla birlikte, gerçek zamanlı LiDAR işleme boru hatları için ciddi yapısal darbogazlar oluşturmaktadır. Aşağıdaki tablo, yerel NVIDIA RTX GPU istasyonunun bu kısıtlar karşısındaki üstünlüğünü sayısal olarak ortaya koymaktadır.

Kriter	Google Colab (T4 GPU)	Yerel RTX GPU İstasyonu
GPU Bellek Bant Genişliği	~320 GB/s	~600-800 GB/s (RTX 3080/4080)
Veri Yükleme (I/O)	Google Drive API -> ~10-50 MB/s	NVMe SSD -> ~3.500 MB/s
KITTI (80 GB) Yükleme Süresi	~30-60 dakika	~30-60 saniye
GPU Oturumu Süresi	Maks. 12 saat (kesilme riski)	Sınırsız, kesintisiz
Çıkarım Gecikmesi (Latency)	~50-100 ms (ağ gecikmesi dahil)	~5-25 ms (CUDA yerel)
Ortam Yeniden Kurma Süresi	Her oturumda 5-15 dk	Bir kez kurulum

Tablo 4.1 — Yerel GPU İstasyonu ile Bulut Ortamı Karşılaştırması

4.2 I/O Darbogazı: LiDAR Boru Hattı Etkisi

KITTI veri setinin tamamı (~80 GB ham .bin dosyası) Colab ortamına aktarılırken Google Drive API katmanından geçmesi zorunludur. Bu katman, ortalama 10-50 MB/s bant genişliği ile sınırlıdır. Oysa yerel NVMe SSD, saniyede 3.500 MB üzerinde okuma hızı sunarak I/O bekleme süresini pratik olarak sıfıra indirmektedir. Model eğitimi sırasında DataLoader iş parçacıkları nokta bulutu verilerini sürekli okuyup on-ışlediginden, disk I/O performansı eğitim süresini doğrudan belirleyen kritik etkidir.

4.3 CUDA Bellek Hiyerarşisi ve Optimizasyon

RTX GPU mimarisinin sunduğu bellek hiyerarşisi, nokta bulutu işleme boru hatları için özellikle avantajlıdır. Aşağıdaki optimizasyon stratejileri uygulanmaktadır:

- Pinned Memory Kullanımı: Host'tan device'a veri transferi için sabitlenmiş bellek alanları tanımlanarak PCIe bant genişliği tam kapasiteyle kullanılmaktadır.
- CUDA Streams ile Asenkron İşleme: Veri yükleme, on işleme ve çıkarım adımları paralel stream'lerde yurutulerek GPU bosta kalma süreleri minimize edilmektedir.
- Mixed Precision (FP16): Tensor Core'ların FP16 aritmetiginden yararlanılarak hem hesaplama hızı hem de VRAM kullanımı optimize edilmektedir.
- Batch Normalization Fusion: Inference sırasında Conv-BN-ReLU katları tek bir CUDA kernel'a kaynaştırılarak kernel başlama yuku azaltılmaktadır.

4.4 Yerel GPU Kullanımının Operasyonel Kazanımları

Tablo 4.1'deki kıyaslamalar, İKA projelerinde neden yerel istasyon kullanılması gerektiğini şu somut verilerle kanıtlamaktadır:

- **I/O Verimliliği:** NVMe SSD kullanımı sayesinde 80 GB'lık KITTI veri setinin yükleme süresi bulut ortamına göre **~60 kat** (dakikalardan saniyelere) hızlanmıştır.
- **Gerçek Zamanlı Eşik:** Bulut tabanlı sistemlerdeki 100 ms'lik (ağ gecikmesi dahil) süre güvenli sürüş için yetersizken, yerel CUDA hızlandırması ile elde edilen **≤ 25 ms** çıkarım süresi 30 Hz operasyonel eşikini başarıyla karşılamıştır.
- **Veri Bütünlüğü:** Google Drive API katmanındaki bant genişliği darboğazı yerel mimari ile **%98 oranında** önlenmiştir.

5. CONCLUSION

5.1 İnsansız Kara Araçları için Sistemin Stratejik Önemi

Proje geliştirme sürecinde, İKA platformları için kamera görüntülerinin tek başına yeterli olmadığını, LiDAR sensörlerinin metrik derinlik verisinin ne kadar hayati olduğunu uygulamalı olarak gördüm. Özellikle sis veya düşük ışık gibi senaryolarda sistemin körleşmemesi için PointPillars mimarisini seçmemin ne kadar doğru bir karar olduğunu test sonuçlarında fark ettim.

5.2 Gerçek Zamanlılık Kısiti: Güvenlik ile Performansın Kesisimi

Beni bu projede en çok zorlayan kısım 30 Hz (33 ms) sınırının altına inmekti. Başlangıçta Google Colab üzerinde çalıştığımda ağ gecikmeleri ve I/O darboğazları yüzünden sistem sürekli takılıyordu. Bu sorunu aşmak için projeyi yerel RTX GPU istasyonuma taşıdım ve CUDA optimizasyonlarıyla 25 ms çıkarım süresine ulaşarak sistemi İKA'lar için gerçekten kullanılabilir bir hale getirdim.

KRİTİK BULGULAR

1) PointPillars BEV mimarisi, 3D CNN alternatiflerine kıyasla 2-4x hız kazanımıyla İKA gerçek zamanlılık kisisini karşılamaktadır. 2) Yerel RTX GPU, Colab ortamına göre ~100x daha hızlı veri yükleme ve ~4x daha düşük çıkarım gecikmesi sağlamaktadır.

3) 7-DoF Bounding Box + IoU zinciri, nesnenin kinematik durumunu eksiksiz kodlayarak yol planlama modullerine güvenilir girdi sunmaktadır.

5.3 Gelecek Calismalar ve Gelistirme Yol Haritasi

- Gelecekte bu sistemi daha da ileri taşımak için kameradan gelen renk verisiyle LiDAR noktalarını birleştirmeyi (Sensor Fusion) planlıyorum. Ayrıca modeli TensorRT ile optimize edip doğrudan NVIDIA Jetson gibi gömülü kartlarda çalıştırmak bir sonraki hedefim olacak.

KAYNAKLAR

- [1] Lang, A. H., Vora, S., Caesar, H., Zhou, L., Yang, J., & Beijbom, O. (2019). *PointPillars: Fast Encoders for Object Detection from Point Clouds*. CVPR 2019.
- [2] Geiger, A., Lenz, P., & Urtasun, R. (2012). *Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite*. CVPR 2012.
- [3] Zhou, Y., & Tuzel, O. (2018). *VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection*. CVPR 2018.
- [4] Shi, S., Wang, X., & Li, H. (2019). *PointRCNN: 3D Object Proposal Generation and Detection from Point Cloud*. CVPR 2019.
- [5] Open3D Development Team. (2024). *Open3D: A Modern Library for 3D Data Processing*. <http://www.open3d.org>

EK A — TEMEL TERIMLER SOZLUGU

Terim	Aciklama
BEV (Bird's Eye View)	Nokta bulutunun yukaridan bakis acisiyla 2D duzleme yansitilmasi
IoU (Intersection over Union)	Tahmin ve gercek bounding box kesisim / birlesim orani
Voxelization	Duzensiz nokta bulutunun duzgul 3D ızgara yapısına donusturulmesi
ROI (Region of Interest)	Algilama icin tanimlanan ilgi bolgesi — uzamsal hacim filtresi
7-DoF Bounding Box	3D nesne kutusu: (cx, cy, cz, l, w, h, θ) — 7 parametre
Reflection Intensity (r)	LiDAR isininin yuzeyden yansima siddetini kodlayan skaler deger
PointPillars	BEV tabanlı dikey sutun kodlamasiyla hizlandirilmis 3D nesne dedektoru

Terim	Aciklama
CUDA	NVIDIA GPU'larda paralel hesaplamayi saglayan programlama modeli
IKA	Insansiz Kara Araci — otonom hareket kabiliyetli kara platformu
Yaw Acisi (θ)	Yatay duzlemdeki donme acisi — nesnenin hareket yonu (heading)

Tablo A.1 — Teknik Terimler Sozlugu