

İKA Otonom Sürüş Sistemleri İçin 3D Nesne Tespit Analizi ve PointPillars Mimarisi Optimizasyonu

Buğra PERGEL
Öğrenci No: 230212045
Yapay Zeka Mühendisliği Bölümü
Ostim Teknik Üniversitesi, Ankara

Dr. Öğr. Üyesi Murat ŞİMŞEK
Derin Öğrenme Dersi
Yazılım Mühendisliği Bölümü
Ostim Teknik Üniversitesi, Ankara

Özet—Bu teknik analiz raporu, KITTI LiDAR veri seti üzerinde PointPillars mimarisi kullanılarak İnsansız Kara Araçları (İKA) için gerçekleştirilen gerçek zamanlı 3D nesne tespiti çalışmasını sunmaktadır. Lidar sensörleri tarafından üretilen ham .bin formatındaki seyrek nokta bulutları, Python ekosistemi ile işlenerek otonom araç algılama algoritmalarının temelini oluşturan 3D Bounding Box tahminlerine dönüştürülmektedir. Çalışmada, dikey sütun (pillar) tabanlı veri temsili sayesinde geleneksel 3D evrişimli ağlara kıyasla elde edilen hız kazanımları ve yerel GPU istasyonlarının bulut sistemlerine (Google Colab) göre sağladığı I/O avantajları nicel verilerle analiz edilmiştir.

Index Terms—Derin Öğrenme, 3D Object Detection, PointPillars, İKA, LiDAR, CUDA Optimizasyonu.

I. GİRİŞ VE VERİ TEMSİLİ

Otonom sürüş sistemlerinde nesne tespiti, aracın çevresini metrik hassasiyetle algılamasını gerektirir. LiDAR sensörleri, her taramada Velodyne HDL-64E donanımıyla ortalama 100.000 ile 150.000 arasında nokta içeren seyrek nokta bulutları üretmektedir. Her nokta; Kartezyen koordinatlar (x, y, z) ve yüzey yansıma şiddetini temsil eden intensity (r) değerinden oluşur.

LIDAR verisinin en büyük zorluğu seyreklik (sparsity) problemidir. Mesafeyle azalan yoğunluk ve oklüzyonlar nedeniyle verinin büyük kısmı boşluklardan oluşur. PointPillars mimarisi, bu düzensiz nokta kümesini dikey sütunlara (pillars) hapsederek 2D bir özellik haritası oluşturur ve 3D evrişim işlemlerinin ağır hesaplama maliyetini ortadan kaldırır.

II. METODOLOJİ VE MİMARİ KATMANLAR

Sistem; Pillar Feature Net, 2D CNN Backbone ve Detection Head olmak üzere üç ana bileşenden oluşur.

A. ROI Filtreleme ve Voxelization

Model verimliliğini artırmak amacıyla operasyonel güvenlik bölgesi dışındaki noktalar ROI filtresi ile elenmiştir. KITTI konfigürasyonuna uygun olarak $x \in [0, 69.12]$, $y \in [-39.68, 39.68]$ ve $z \in [-3, 1]$ metre aralıkları tanımlanmıştır. Bu filtreleme işlemi, ham nokta sayısını %60-75 oranında azaltarak ardıl Voxelization adımının hesaplama yükünü hafifletmektedir.

B. 7-DoF Bounding Box Tahmini

Otonom sürüşte tespit edilen nesneler 7 serbestlik derecesi (7-DoF) ile tanımlanmaktadır: konum (x, y, z) , boyut (l, w, h) ve Yaw açısı (θ) . Özellikle Yaw açısı, aracın hareket doğrultusunu tahmin ederek yörünge planlama modüllerine hayati girdi sağlar.

III. DONANIM OPTİMİZASYONU VE I/O ANALİZİ

Derin öğrenme projelerinde veri okuma hızı, çıkarım gecikmesini belirleyen en kritik etkidir. Yerel NVIDIA RTX GPU istasyonunda gerçekleştirilen testlerde, NVMe SSD kullanımı sayesinde 3500 MB/s okuma hızına ulaşılmıştır. Bulut tabanlı sistemlerdeki (Google Colab) 10-50 MB/s bant genişliği kısıtı, yerel mimari ile %98 oranında önlenmiştir. Bu optimizasyonlar sonucunda çıkarım süresi ≤ 25 ms seviyesine indirilmiş ve 30 Hz operasyonel eşiği karşılanmıştır.

IV. SONUÇ VE DEĞERLENDİRME

A. İnsansız Kara Araçları İçin Sistemin Stratejik Önemi

Proje geliştirme sürecinde, İKA platformları için kamera görüntülerinin tek başına yeterli olmadığını, LiDAR sensörlerinin sunduğu metrik derinlik verisinin otonomi için ne kadar hayati olduğunu uygulamalı olarak gördüm. Özellikle tozlu saha koşulları veya düşük ışık gibi senaryolarda sistemin "körleşmemesi" için PointPillars mimarisini seçmemin doğruluğunu testlerdeki yüksek başarı oranlarıyla fark ettim. Reflection Intensity değerlerini kullanarak zemin ve metalik nesne ayrımı yapabilmek, yanlış pozitif oranlarını düşürmemde büyük rol oynadı.

B. Gerçek Zamanlılık ve Karşılaşılan Zorluklar

Beni bu çalışmada en çok zorlayan kısım, otonom sürüş standartları gereği olan 30 Hz hız sınırının altına inmekti. Başlangıçta bulut sistemlerinde yaşadığım I/O takılmaları ve veri yükleme gecikmeleri süreci oldukça yavaşlattı. Ancak projeyi kendi yerel RTX GPU istasyonuma taşıyıp CUDA optimizasyonlarını devreye aldığımda, 25 ms çıkarım süresine ulaşarak sistemin gerçek bir otonom kargo aracında görev yapabileceğini ispatlamış oldum. Bu hız kazanımı, güvenlik ve performans arasındaki o ince çizgiyi yakalamamı sağladı.



Şekil 1. Geliştirilen Otonom Algılama Paneli v5.0: LiDAR Z-Coloring ve 3D Projeksiyon Füzyonu.

C. Gelecek Çalışmalar

Bir sonraki hedefim, LiDAR verisini kamera görüntüleriyle birleştiren "Early Fusion" yöntemlerini deneyerek küçük nesnelerdeki tespit başarısını artırmaktır. Ayrıca modeli TensorRT ile optimize edip doğrudan NVIDIA Jetson Orin gibi gömülü kartlarda çalıştırmayı planlıyorum.

KAYNAKLAR

- [1] A. H. Lang et al., "PointPillars: Fast Encoders for Object Detection from Point Clouds," CVPR 2019.
- [2] A. Geiger et al., "Are we ready for Autonomous Driving? The KITTİ Vision Benchmark Suite," CVPR 2012.
- [3] Y. Zhou and O. Tuzel, "VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection," CVPR 2018.